

Schemat bazy danych – polea_*

Opis osobnej bazy MySQL zasilanej przez scraper i czytanej (tylko do odczytu) przez wtyczkę WordPress. Plik źródłowy DDL: db/schema.sql (to on jest autorytatywny – ten dokument go objaśnia).

Zasady ogólne

- Silnik InnoDB, kodowanie utf8mb4 (utf8mb4_unicode_ci).
- Właścicielem danych jest scraper (upsert). Wtyczka WP tylko czyta.
- Dwie tabele: polea_motocykle (1 wiersz = 1 aukcja) i polea_zdjecia (wiele zdjec na aukcje). Relacja przez lot_id.
- Wymagania: MySQL 5.7+ / MariaDB 10.2+.
- Utworzenie: CREATE DATABASE polea CHARACTER SET utf8mb4 COLLATE utf8mb4_unicode_ci;

potem mysql -u <user> -p polea < db/schema.sql.

Tabela: polea_motocykle

Klucz główny: lot_id (stały identyfikator lotu z URL źródła).

Identyfikacja i adresy

Kolumna	Typ	Opis
lot_id	VARCHAR(32) NOT NULL	PK; ID lotu z URL
numer_aukcji	VARCHAR(64)	np. 3110/BZ/AU/2026
slug	VARCHAR(255)	człon URL
url	VARCHAR(512)	pełny URL szczegółów

Dane pojazdu

Kolumna	Typ	Opis
marka	VARCHAR(64)	producent
model	VARCHAR(128)	model
typ	VARCHAR(64)	np. KROSOWY
rok_produkcji	SMALLINT UNSIGNED	rok
data_pierwszej_rej	DATE	data 1. rejestracji
vin	VARCHAR(20)	numer VIN (17+bufor)
nr_rej	VARCHAR(32)	nr rejestracyjny
naped	VARCHAR(64)	np. Lancuch
skrzynia	VARCHAR(64)	np. Manualna
moc_km	SMALLINT UNSIGNED	moc w KM
pojemnosc_ccm	INT UNSIGNED	pojemnosc w ccm
paliwo	VARCHAR(32)	rodzaj paliwa
przebieg_km	INT UNSIGNED	przebieg
kolor	VARCHAR(64)	kolor
ilosc_kluczykow	TINYINT UNSIGNED	liczba kluczykow
forma_sprzedazy	VARCHAR(64)	np. faktura VAT

Dane aukcyjne

Kolumna	Typ	Opis
cena_pln	DECIMAL(12,2)	aktualna cena
cena_netto	TINYINT(1) NOT NULL=1	1=netto, 0=brutto
najnizsza_cena_30d	DECIMAL(12,2)	Omnibus: najnizsza z 30 dni
tryb_licytacji	VARCHAR(64)	np. sprzedaz ofertowa
lokalizacja	VARCHAR(255)	miejsce pojazdu

termin_zakonczenia	DATETIME	koniec aukcji (czas lokalny zrodla)
status	VARCHAR(32) NOT NULL	aktywna / zakonczona / usunieta
liczba_ofert	INT UNSIGNED NOT NULL=0	liczba ofert
uwagi	TEXT	uwagi zrodla

Meta pipeline (dedup / diff / reconcile)

Kolumna	Typ	Opis
raw_hash	CHAR(32)	MD5 rekordu -> wykrywanie zmian
relist_of	VARCHAR(32)	lot_id nowszej aukcji tego VIN; NULL=najnowszy
first_seen	TIMESTAMP	pierwsze zobaczenie (auto)
last_seen	TIMESTAMP	ostatni import (auto)
updated_at	TIMESTAMP ON UPDATE	ostatnia zmiana (auto)

Kolumny first_seen / last_seen / updated_at ustawia sama baza – scraper ich nie podaje.

Indeksy

Indeks	Kolumny	Cel
PRIMARY	lot_id	klucz glowny
idx marka	marka	filtr po marce
idx_status	status	filtr aktywnych
idx_termin	termin_zakonczenia	sortowanie
idx_status_termin	status, termin_zakonczenia	zapytanie listy (WHERE status + ORDER BY termin)
idx_vin	vin	dedup po VIN
idx_last_seen	last_seen	reconcile / diagnostyka

Tabela: polea_zdjecia

Zdjecia hotlinkowane; kolejnosc przez sort_order.

Kolumna	Typ	Opis
id	BIGINT UNSIGNED AI	PK
lot_id	VARCHAR(32) NOT NULL	FK -> polea_motocykle.lot_id
image_key	VARCHAR(64) NOT NULL	UUID z nazwy pliku
url	VARCHAR(512) NOT NULL	pelny URL zdjecia
sort_order	SMALLINT UNSIGNED NOT NULL=0	kolejnosc

Klucze: PK id; UNIQUE uq_lot_image (lot_id, image_key) – idempotentny upsert;
KEY idx_lot (lot_id); FK fk_zdjecia_lot z ON DELETE CASCADE (usuniecie lotu kasuje jego zdjecia).

Przeplyw danych (upsert)

- Aukcje: INSERT ... ON DUPLICATE KEY UPDATE ... po lot_id (+ last_seen=NOW()).
- Zdjecia: INSERT ... ON DUPLICATE KEY UPDATE url, sort_order po (lot_id, image_key).
- Reconcile: aukcje aktywne, ktorzych nie ma w biezacym crawlu -> status='zakonczone'

(z bezpiecznikiem POLEA_RECONCILE_MIN_RATIO).

Zgodnosc (zapis = schemat = odczyt)

Zapis scrapera (scraper/dzial4_synchronizacja.py, lista _FIELDS) pokrywa dokladnie kolumny schematu (poza auto-timestampami). Normalizacja (scraper/dzial2_normalizacja.py) przycina teksty do dlugosci kolumn i zawsze wypelnia pola NOT NULL. Wtyczka czyta wylaczenie podzbior tych kolumn. Ten kontrakt jest zweryfikowany testami i audytem.